

Spark SQL 核心知识 2

目录

1、	Spark On YARN	1
	1.1、配置 Spark 整合 YARN	
	1.2、Spark-Shell 测试	
	1.3、Spark-Submit 测试	
2、	Spark 整合 Hive	
	2.1、Spark 自带元数据库	
	2.2、Spark 整合 Hive 配置	
	2.3、Spark SQL 脚本使用	
		7
	2.4.1、spark-1.x 版本	
	2.4.2、spark-2.x 版本	8
3、	SparkSQL 自定义聚合函数	
	. 3.1、SparkSQL 定义普通函数	8
	· 3.2、定义 SparkSQL 的自定义聚集函数	
	3.3、使用测试	
4、	SparkSQL 常用窗口分析函数	
	综合练习	

1、Spark On YARN

1.1、配置 Spark 整合 YARN

1、设置 HADOOP_CONF_DIR

export HADOOP_CONF_DIR=/home/hadoop/apps/hadoop-2.7.6/etc/hadoop/

```
export JAVA_HOME=/usr/local/java/jdk1.8.0_73
export SPARK_MASTER_PORT=7077
export SPARK_DAEMON_JAVA_OPTS="-Dspark.deploy.recoveryMode=ZOOKEEPER -Dspark.deploy.zexport SPARK_HISTORY_OPTS="-Dspark.history.ui.port=18080 -Dspark.history.retainedApp]
export HADOOP_CONF_DIR=/home/hadoop/apps/hadoop-2.7.6/etc/hadoop/
```

2、拷贝 yarn-site.xml, hdfs-site.xml, core-site.xml 配置文件到\$SPARK_HOME 下,重点是yarn-site.xml,因为在搭建 spark HA 集群的时候,就已经把 core-site.xml 和 hdfs-site.xml 放置在这个目录下了。



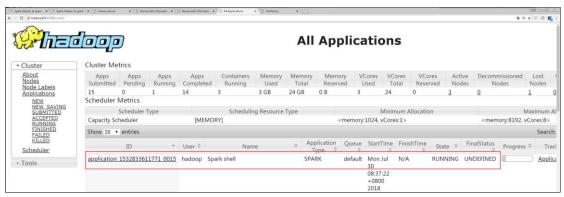
```
[hadoop@hadoop02 conf]$ 11
total 64
-rw-r--r-- 1 hadoop hadoop 1570 Jun 16 19:04 core-site.xml
-rw-rw-r-- 1 hadoop hadoop 996 Jun 16 19:01 docker.properties.template
-rw-rw-r-- 1 hadoop hadoop 1105 Jun 16 19:01 fairscheduler.xml.template
-rw-r--r-- 1 hadoop hadoop 4085 Jun 16 19:04 hdfs-site.xml
-rw-rw-r-- 1 hadoop hadoop 2909 Jul 26 18:50 hive-site.xml
-rw-rw-r-- 1 hadoop hadoop 2025 Jun 25 10:49 log4j.properties
-rw-rw-r-- 1 hadoop hadoop 2025 Jun 16 19:01 log4j.properties.template
-rw-rw-r-- 1 hadoop hadoop 7801 Jun 16 19:01 metrics.properties.template
-rw-rw-r-- 1 hadoop hadoop 893 Jun 16 19:01 slaves
-rw-rw-r-- 1 hadoop hadoop 865 Jun 16 19:01 slaves.template
-rw-rw-r-- 1 hadoop hadoop 1400 Jul 19 20:57 spark-defaults.conf
-rw-rw-r-- 1 hadoop hadoop 1292 Jun 16 19:01 spark-defaults.conf.template
-rwxrwxr-x 1 hadoop hadoop 4685 Jul 19 20:57 spark-env.sh
-rw-r--r-- 1 hadoop hadoop 2503 Jul 19 21:04 yarn-site.xml
[hadoop@hadoop02 conf]$
```

3、启动 Spark-Shell

spark-shell \

- --master yarn \
- --deploy-mode client \
- --executor-memory 512m \
- --total-executor-cores 1

```
Whadcopp2 | whadcopp3 | whadco
```



如果报错是关于 yarn-application 资源相关的问题的,请在 yarn-site.xml 配置文件中加入:

cproperty>

<name>yarn.nodemanager.vmem-check-enabled</name> <value>false</value>



1.2、Spark-Shell 测试

val listWords = List("hello world", "word count", "hello hello lijie", "lalala lijie")
val countWord1 = listWords.map(_.split(" ")).flatten.map((_,1)).groupBy(_._1).map(t =>
(t._1,t._2.size)).toList.sortBy(_._2).reverse

```
| Chadopo@hadopo@s | Spank-shell --master yarn --executor-memory 512m --total-executor-cores 1 | 18/07/30 08:04:19 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable 18/07/30 08:04:26 WARN Client: Neither spark.yarn.jars nor spark.yarn.archive is set, falling back to uploading libraries under SPARK_HOME. Spark context Web UI available as 'sc' (master = yarn, app id = application_1532833611771_0012). Spark session available as 'spark'.

Welcome to

Using Scala version 2.11.8 (Java HotSpot(TM) 64-Bit Server VM, Java 1.8.0.73)
Type in expressions to have them evaluated.

Type :help for more information.

scala>

scala> val listWords = List("hello world", "word count", "hello hello lijie", "lalala lijie")

listWords: List[String] = List(hello world, word count, hello hello lijie, lalala lijie)

scala> val countWord1 = listWords.map(_.split(" ")).flatten.map((_,1)).groupBy(_.1).map(t => (t._1,t._2.size)).toList.sortBy(_._2).reverse countWord1: List[(String, Int)] = List((hello,3), (lijie,2), (lalala,1), (word,1), (world,1), (count,1))
```

1.3、Spark-Submit 测试

高可用方式下使用 spark-submit 提交一个任务到高可用的 YARN 集群,使用 client 模式:

- ~/apps/spark-2.3.1-bin-hadoop2.7/bin/spark-submit \
- --class org.apache.spark.examples.SparkPi \
- --master yarn \
- --deploy-mode client \
- --executor-memory 512m \
- --total-executor-cores 1 \



~/apps/spark-2.3.1-bin-hadoop2.7/examples/jars/spark-examples_2.11-2.3.1.jar \ 100

```
| This park | Whitened | Whitened
```

高可用方式下使用 spark-submit 提交一个任务到高可用的 YARN 集群,使用 cluster 模式:

- ~/apps/spark-2.3.1-bin-hadoop2.7/bin/spark-submit \
- --class org.apache.spark.examples.SparkPi \
- --master yarn \
- --deploy-mode cluster \
- --executor-memory 512m \
- --total-executor-cores 1 \
- ~/apps/spark-2.3.1-bin-hadoop2.7/examples/jars/spark-examples_2.11-2.3.1.jar \ 100

```
[hadoop@hadoop@2 conf]$ ~/apps/spark-2.3.1-bin-hadoop2.7/bin/spark-submit \
> --class org.apache.spark.examples.SparkPi \
> --deploy-mode cluster \
> --executor-memory 512m \
> --total-executor-cores 1 \
> ~/apps/spark-2.3.1-bin-hadoop2.7/examples/jars/spark-examples_2.11-2.3.1.jar \
> /apps/spark-2.3.1-bin-hadoop2.7/examples/jars/spark-examples_2.11-2.3.1.jar \
100
18/07/30 08:32:51 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable 18/07/30 08:32:52 WARN Client: Neither spark.yarn.jars nor spark.yarn.archive is set, falling back to uploading libraries under SPARK_HOME.
[hadooop@adoop@2 conf]$
```

2、Spark 整合 Hive

2.1、Spark 自带元数据库

在\$SPARK_HOME/conf 目录下如果没有 hive-site.xml 文件的情况下。 Spark 使用的元数据库是默认的 in-memory 模式,也就是使用自带的 derby 在当前会话中有效



2.2、Spark 整合 Hive 配置

把 hive-site.xml 配置文件放到\$SPARK_HOME/conf 目录中 然后两种方式配置:

启动 hive 的 metastore 服务

2.3、Spark SQL 脚本使用

在 hive 中的操作:



```
♦ hadoop02 | ♦ hadoop02 (1) | ♦ hadoop03 | ♦ hadoop03 (1) | ♦ hadoop04 | ♦ hadoop05 x | ♦ hadoop05 (1)
hive> show databases;
OK
default
mydb_test
myhive
Time taken: 2.512 seconds, Fetched: 3 row(s)
hive> use myhive;
Time taken: 0.047 seconds
hive> show tables;
OK
student
student_s
Time taken: 0.067 seconds, Fetched: 2 row(s)
hive> select * from student;
OK
95002
         刘晨
                         19
                                  IS
95017
         王风娟
                 女
                         18
                                  IS
95018
                 女
                         19
                                  IS
        冯伟
95013
                                  CS
95014
        王小丽
                 女
                                  CS
                         19
        邢小丽
95019
                         19
95020
        赵钱
                 男
                         21
                                  IS
        王敏
                 女
95003
                         22
                                  MA
        张立
                 男
95004
                         19
                                  TS
                 女
         孙花
95012
                         20
                                  CS
95010
        孔小涛
                 男
                         19
                                  CS
                 男
        刘刚
孙庆
95005
                         18
                                  MA
95006
                         23
                                  CS
         易思玲
95007
                 女
                         19
                                  MA
                 女
        李娜
95008
                         18
                                  CS
        周二
郑明
95021
                         17
                                  MA
95022
                         20
                                  MA
95001
         李勇
                 男
                         20
                                  CS
        包小柏
95011
                         18
                                  MA
        梦圆圆
                 女
95009
                         18
                                  MA
         王君
95015
                         18
                                  MA
Time taken: 1.068 seconds, Fetched: 21 row(s)
hive>
```

在 spark-sql 中的操作:

```
(hadoopshadops06 ~ 15 sank-sql
18/07/30 08:41:11 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
18/07/30 08:41:11 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
18/07/30 08:41:11 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
18/07/30 08:41:11 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
18/07/30 08:41:11 WARN NativeCodeLoader: Native Code
18/07/30 08:41:11 WARN Native Code
18/07/30 08:41 WARN Native Code
18
```



2.4、IDEA 编写 Spark 程序读写 Hive

2.4.1、spark-1.x 版本

```
* 作者: 马中华 https://blog.csdn.net/zhongqi2513
* 时间: 2018/5/26 17:53
* 描述: 编写SparkSQL程序读取Hive中的数据
* 拨行之前, 必须先把metastore服务启动起来, 启动Hive 的 metastore 服务
* nohup hive --service metastore 1>/home/hadoop/logs/hive_thriftserver.log 2>&1 &
* 启动hiveserver2服务
* // -DHADOOP_USER_NAME=hadoop 或者不添加下面的代码, 可以给JVM设置一个这样的参数
System.setProperty("HADOOP_USER_NAME", "hadoop")
val conf = new SparkConf().setMaster("local").setAppName("SparkSQL_Hive_1")
val sc = new SparkContext(conf)
val hiveContext = new HiveContext(sc)

hiveContext.sql(sqlText = "select * from myhive.student").show()

sc.stop()
}
```



2.4.2、spark-2.x 版本

```
* 作者: 马中华 https://blog.csdn.net/zhongqi2513
* 时间: 2018/5/26 17:57
* 描述: 使用Spark2.x版本的API编写Spark代码整合Hive
*/
object SparkSQL_Hive_2 {

def main(args: Array[String]): Unit = {

System.setProperty("HADOOP_USER_NAME", "hadoop")

val sparkSession:SparkSession = SparkSession.builder()
    .appName(name = "SparkSQL_Hive_2")
    .master(master = "local")
    .enableHiveSupport()
    .getOrCreate()

sparkSession.sql(sqlText = "select * from myhive.student").show()

sparkSession.stop()
}
}
```

3、SparkSQL 自定义聚合函数

3.1、SparkSQL 定义普通函数

要点: spark.udf.register("function_name", function)



3.2、定义 SparkSQL 的自定义聚集函数

Class MyUDAF extends UserDefinedAggregationFunction spark.udf.register("function_name", function)

```
package com.aura.mazh.spark.sql.udf

import org.apache.spark.sql.Row
import org.apache.spark.sql.expressions.{MutableAggregationBuffer,
UserDefinedAggregateFunction}
import org.apache.spark.sql.types._

/**

* 定义Student.txt 中,求学生平均年龄的一个自定义函数

*

* 计算规则:

* 1、统计出所有学生的年龄之和total

* 2、统计出所有学生的个数count

*/
object SparkSQL_UDAF_AvgAge extends UserDefinedAggregateFunction{
```



```
* 定义输入的数据的类型
override def inputSchema: StructType = StructType(
 StructField("age", DoubleType, true) :: Nil
)
 * 定义辅助字段:
 * 1、辅助字段1: 用来记录所有年龄之和 total
 * 2、辅助字段 2: 用来总记录所有学生的个数 count
override def bufferSchema: StructType = StructType(
 StructField("total", DoubleType, true)::
 StructField("count", IntegerType, true)::
 Nil
)
 * 计算学生的平均年龄 计算公式: 学生年龄的总和 / 学生总数
 * 所以要初始化要两个辅助字段:
      total : 0.0
      count : 0
override def initialize(buffer: MutableAggregationBuffer): Unit = {
 buffer.update(0, 0.0)
 buffer.update(1, 0)
}
  * 每次给一条记录, 然后进行累加。进行累加变量 buffer 的状态更新
 * 这是一个局部操作。
override def update(buffer: MutableAggregationBuffer, input: Row): Unit = {
 val lastTotal = buffer.getDouble(0)
 val lastCount = buffer.getInt(1)
 val currentSalary = input.getDouble(0)
 buffer.update(0,lastTotal + currentSalary)
 buffer.update(1,lastCount+1)
}
```



```
/**
  * 当局部操作完成,最后需要一个全局合并的操作
 * 就相当于是 reducer 阶段的最终合并
override def merge(buffer1: MutableAggregationBuffer, buffer2: Row): Unit = {
 val total1 = buffer1.getDouble(∅)
 val count1 = buffer1.getInt(1)
 val total2 = buffer2.getDouble(0)
 val count2 = buffer2.getInt(1)
 buffer1.update(0, total1 + total2)
 buffer1.update(1, count1 + count2)
}
 * 计算平均年龄
override def evaluate(buffer: Row): Any = {
 val total = buffer.getDouble(0)
 val count = buffer.getInt(1)
 total / count
}
 * 返回结果数据类型
override def dataType: DataType = DoubleType
 * 输入和输出的字段类型是否匹配。也即是否一致
override def deterministic: Boolean = true
```



3.3、使用测试

4、SparkSQL常用窗口分析函数

见文档"案例 08--Hive 各种分析函数案例.rar"

5、综合练习

SparkCore 影评案例的第八题 sparkcore 实现 sparksql 实现 SparkCore 拉勾的第四题 sparkcore 实现 sparksql 实现 NBA 案例